

Deteksi dan klasifikasi kanker payudara menggunakan Random Forest dan kNN

- **Topik/Domain:** Kesehatan & Medis - Prediksi Risiko Kanker Payudara (Breast Cancer): Klasifikasi tumor jinak (benign) atau ganas (malignant) berdasarkan ekstraksi fitur numerik massa payudara.
- **Kelompok:** Dua (2)
- **Anggota Kelompok:**
 1. M. Rayhant Al Munawar - 11241059
 2. Thisya Darmala - 11241083
 3. Gian Al Haritz Ueldy Secondri - 11241033
 4. Muhammad Rizal - 11241049

1. PENDAHULUAN

1. Latar Belakang & Tujuan

Kanker payudara memerlukan deteksi dini yang akurat melalui klasifikasi tumor (jika jinak atau ganas) untuk memerlukan tindakan medis yang tepat dan meningkatkan angka kelangsungan hidup pasien. Dalam artikel penggunaan algoritma Regresi Logistik memberikan solusi diagnosis yang efisien, akurat, dan mudah diinterpretasikan, sehingga membantu tenaga medis memahami faktor kunci dalam klasifikasi sekaligus prosedur invasif yang tidak perlu.

Adapun tujuan penelitian :

1. Mengembangkan model klasifikasi berbasis regresi logistik menggunakan Wisconsin Diagnostic Breast Cancer melalui tahapan pra-pemrosesan serta eksplorasi fitur numerik massa payudara seperti ukuran, bentuk, dan tekstur.
2. Melatih dan mengevaluasi kinerja model untuk memastikan tingkat akurasi yang tinggi dalam membedakan antara tumor jinak (benign) dan ganas (malignant) guna memberikan hasil prediksi yang valid dan reliabel.
3. Mendukung pengambilan keputusan klinis dengan menyediakan model yang efisien dan mudah diinterpretasikan untuk memfasilitasi deteksi dini serta perencanaan perawatan yang tepat meningkatkan angka harapan hidup pasien.

2. Dataset:

Dataset	Jumlah Baris	Jumlah Fitur
Breast Cancer Wisconsin (Diagnostic) Data Set	569	32

3. Paper Referensi Utama:

[BREAST CANCER CLASSIFICATION USING LOGISTIC REGRESSION.](#)

2. PROGRES PRA-PEMROSESAN DATA & EDA

1. Pembersihan Data

Data dipastikan bersih sejak awal karena tidak ditemukan missing values (nilai kosong) maupun baris data yang duplikat. Penyesuaian yang dilakukan adalah penyeragaman

tipe label variabel target diagnosis, di mana format teks 'M' (Malignant) dikonversi menjadi angka 1, dan 'B' (Benign) menjadi angka 0.

2. Transformasi Fitur:


Feature Engineering: Telah memproduksi 3 variabel fitur baru untuk meningkatkan performa model, yaitu: `area_perimeter_ratio` (indikasi bentuk/kepadatan), `radius_growth_ratio` (indikasi pertumbuhan abnormal), dan `concavity_score` (gabungan `concavity_mean` dan `concave points_mean`).

Feature Encoding: Menerapkan Ordinal Encoding pada kolom `radius_mean` untuk membuat kolom kategori baru bernama `RadiusCategory`. Data dikategorikan menjadi Small (0), Medium (1), dan Large (2).


Feature Scaling: Menggunakan `StandardScaler` pada matriks akhir keseluruhan fitur untuk menormalisasi mean tiap kolom, memastikan tidak ada fitur yang mendominasi hanya karena satuan skalanya lebih besar.

3. Exploratory Data Analysis (EDA) Lanjutan:

Analisis matriks korelasi menemukan 10 fitur teratas yang sangat berkorelasi dengan target keganasan tumor, dengan 3 teratas adalah `concave points_worst` (0.79), `perimeter_worst` (0.78), dan `concave points_mean` (0.77).



Visualisasi menggunakan Density Plot (KDE) dan Boxplot menunjukkan perbedaan separasi distribusi data yang cukup tajam antara kelas Benign dan Malignant, khususnya pada fitur seperti radius_mean dan concavity_mean.



3. IMPLEMENTASI & EKSPERIMEN MODEL

1. Eksperimen Baseline (Review):

Algoritma dasar yang digunakan merujuk pada referensi paper utama, yaitu Regresi Logistik (Logistic Regression). Pemilihan algoritma ini didasari oleh kelebihan yang sederhana, efisien secara komputasi, dan mudah diinterpretasikan (sesuai paper referensi). Model ini dilatih menggunakan parameter konstan random_state=42 pada data yang telah disesuaikan skalanya. Model baseline ini sejak awal telah memberikan performa sangat apik dengan Balanced Accuracy 97.06% dan Akurasi Keseluruhan 98%, serta hanya membuat 10 kesalahan prediksi dari 456 data uji.

2. Optimasi & Parameter Tuning:

pada tahap eksperimen ini, model langsung dikonfigurasi menggunakan parameter spesifik yang telah ditentukan untuk menyesuaikan dengan pola persebaran fitur numerik dataset. Pada tahap eksperimen ini, model dikonfigurasi secara langsung dengan parameter spesifik yang telah ditetapkan. Hal ini bertujuan untuk memastikan model beradaptasi dengan pola distribusi fitur numerik yang ada pada *dataset*.

K-Nearest Neighbors (kNN):

Model diimplementasikan dengan mengatur parameter jumlah tetangga ($n_neighbors$) = 5, pembobotan ($weights$) = 'distance', dan matriks perhitungan jarak ($metric$) = 'euclidean'.

Random Forest:

Model ansambel dibangun dengan konfigurasi jumlah pohon ($n_estimators$) = 200, pengaktifan bootstrap = True, kedalaman pohon maksimal (max_depth) = 10, batas minimum pemisahan sampel ($min_samples_split$) = 2, dan jumlah fitur ($max_features$) = 'sqrt'.

3. Tabel Komparasi Performa (Sementara):

Evaluasi akhir dilakukan pada data *validasi/testing*. Sesuai dengan fokus eksperimen, komparasi performa model-model yang telah dilatih tidak hanya menggunakan Akurasi biasa, melainkan juga menyoroti metrik krusial seperti F1-Score dan AUC-ROC untuk mengukur efektivitas model dalam meminimalkan *False Negative* pada deteksi kanker.

Algoritma	Precision	Recall	F1-Score	AUC-ROC
Baseline - Logistic Regression	1.000	0.9412	0.9697	0.9941
Model 1 - KNN	0.9932	0.8529	0.9177	0.9889
Model 2 - Random Forest	0.9745	0.9000	0.9358	0.9910

Kesimpulan :

Dari evaluasi yang dilakukan didapatkan balanced accuracy pada setiap algoritma masing-masing bernilai 0,9706 untuk Logistic Regression, 0.9247 untuk kNN, dan 0,9430 untuk Random Forest. Perbandingan tersebut menunjukkan Logistic Regression memiliki akurasi yang paling konsisten dan kombinasi precision, recall, f1-score, dan AUC-ROC yang cukup tinggi. Random Forest berada di posisi kedua dengan nilai presisi sebesar 0.9745 dan f1-score sebesar 0.9358 menunjukkan keseimbangan dalam menangkap pola kompleks. Urutan terakhir terdapat pada algoritma kNN, algoritma ini cenderung bias ke kelas mayoritas dengan distribusi lebih jelas yang mana pada kasus ini distribusi untuk kelas malignant memiliki nilai lebih tinggi.

4. KENDALA TEKNIS & ANALISIS ERROR

1. Kendala Teknis:

Saat ini belum terdapat kendala teknis yang terlalu kritis, karena proses yang dilakukan masih berada pada tahap awal (data preprocessing dan baseline modeling). Namun, terdapat beberapa potensi, seperti evaluasi performa model yang masih perlu dianalisis lebih lanjut.

2. Upaya Solusi:

Untuk mengantisipasi potensi kendala tersebut, langkah yang telah dilakukan antara lain:

1. Melakukan EDA dan pembersihan data untuk memastikan kualitas input model.
2. Menyiapkan tahap lanjutan berupa hyperparameter tuning.
3. Melakukan evaluasi menggunakan metrik seperti accuracy, precision, recall karena menyangkut pada penyakit medis

5. RENCANA TINDAK LANJUT (NEXT STEPS)

Adapun rencana tindak lanjut yang akan dilakukan kelompok 2 sebagai berikut:

- 1) Melakukan optimisasi model melalui hyperparameter tuning dengan menggunakan teknik seperti RandomizedSearchSV atau GridSearchCV untuk menemukan konfigurasi parameter terbaik dari model yang sudah di uji.
- 2) Melakukan penyempurnaan pipeline machine learning dengan menambahkan komponen PCA (Principal Component Analysis) untuk mereduksi dimensi sehingga data menjadi lebih ringkas.
- 3) Membuat antarmuka sederhana dengan Streamlit untuk menampilkan hasil evaluasi dan prediksi secara real-time.
- 4) Menata Struktur Github, notebook eksperimen, menyusun draft paper yang memuat komparasi model, analisis metrik, dan kesimpulan.

6. LAMPIRAN

- **Tautan Repository GitHub/GitLab (Jika ada):** [\[Link Github\]](#)
- **Tautan Jupyter Notebook Progres Terkini (Google Colab/Kaggle):** [\[Link Google Colab\]](#)